

Processamento Digital de Imagens Ambientais com Python

Segmentação de Vegetação por Índices Espectrais VARI e ExG

Gilberto de Paiva Melo

Matrícula: _____ Turma: _____

Curso de Ciência da Computação — Computação Gráfica

Avaliação A3 — Semestre 2025.1

9 de junho de 2026

Resumo

Este trabalho apresenta um *pipeline* completo de processamento digital de imagens para análise de cobertura vegetal a partir de fotografias RGB, implementado em Python com OpenCV, NumPy, Matplotlib e scikit-image. O sistema realiza aquisição, pré-processamento, análise de histograma, filtragem comparativa (Gaussiano, Mediana e Bilateral), detecção de bordas (Canny), e segmentação de vegetação por índices espectrais de crominância (VARI e ExG). Demonstra-se empiricamente que índices de crominância superam a limiarização de Otsu por luminância na distinção de vegetação, e propõe-se uma segmentação aprimorada combinando o índice ExGR com uma trava de cor em HSV, capaz de eliminar falsos positivos em solo, céu e superfícies acinzentadas. Os experimentos cobrem seis imagens de origem diversa (câmera de celular e drone), evidenciando que a escolha do tipo de imagem é parte integrante do algoritmo.

Palavras-chave: visão computacional; índices de vegetação; VARI; ExG; segmentação; OpenCV.

Sumário

1	Introdução e Contextualização	3
2	Objetivos	3
2.1	Objetivo Geral	3
2.2	Objetivos Específicos	3

3	Fundamentação Teórica	4
3.1	Imagem digital e o modelo RGB	4
3.2	Espaços de cor	4
3.3	Índices de vegetação	4
3.4	Filtros de suavização	5
3.5	Detecção de bordas — Canny	5
3.6	Limiarização de Otsu	5
3.7	Morfologia matemática	5
3.8	Métricas de fidelidade — PSNR e SNR	5
4	Metodologia	5
4.1	Ferramentas	5
4.2	Aquisição das imagens	6
4.3	Pipeline de processamento	6
5	Resultados e Discussão	6
5.1	Aquisição e metadados	6
5.2	Análise de histograma	7
5.3	Índices de vegetação	7
5.4	Filtragem comparativa	7
5.5	Segmentação: Otsu <i>vs.</i> ExG	8
5.6	Segmentação aprimorada	9
5.7	Análise multi-imagem	10
5.8	Pipeline completo	12
6	Análise Crítica	12
7	Conclusão	13

1 Introdução e Contextualização

A Computação Gráfica é a área da Ciência da Computação responsável pela geração, manipulação e análise de imagens por meio de algoritmos. No contexto atual, a visão computacional e o processamento digital de imagens permeiam aplicações que vão de diagnósticos médicos ao monitoramento de ecossistemas.

Este projeto integra a **captura real de imagens** — realizada pelo próprio aluno com câmera de smartphone — ao posterior tratamento digital em Python. O fio condutor é ambiental: quantificar a cobertura vegetal de uma cena diretamente a partir de uma fotografia comum, sem sensores especializados. Tal capacidade tem relevância em agricultura de precisão, monitoramento de desmatamento e análise de áreas verdes urbanas, onde imagens de satélite são caras e pouco frequentes, enquanto um celular captura milhões de pixels instantaneamente.

O olho humano distingue o verde com facilidade, mas o computador enxerga apenas números. O objetivo central é transformar esses números em uma resposta objetiva: *quais pixels correspondem a vegetação e qual o percentual de cobertura*.

2 Objetivos

2.1 Objetivo Geral

Desenvolver um sistema de processamento digital de imagens em Python capaz de analisar imagens capturadas pelo aluno, aplicando técnicas de Computação Gráfica para extrair informação quantitativa de vegetação e realizar tratamentos visuais com fins analíticos e ambientais.

2.2 Objetivos Específicos

- Capturar imagens reais com participação ativa do aluno, documentando equipamentos;
- Implementar pré-processamento: leitura, conversão de espaço de cores, redimensionamento e normalização;
- Aplicar ao menos quatro técnicas distintas: filtros de suavização, detecção de bordas, transformações morfológicas e análise de histograma;
- Realizar segmentação de regiões de interesse por limiarização (Otsu) e por índices espectrais;
- Apresentar resultados comparativos (original $\times$ processado) com análise crítica;
- Documentar todo o processo em relatório técnico e código comentado.

3 Fundamentação Teórica

3.1 Imagem digital e o modelo RGB

Uma imagem digital é uma representação matricial de uma cena, composta por *pixels*. Em imagens coloridas no modelo RGB, cada pixel é descrito por três canais — Vermelho (R), Verde (G) e Azul (B) — com valores inteiros de 0 a 255 (8 bits por canal), totalizando até 16,7 milhões de cores. No NumPy, a imagem é um arranjo de forma $(altura, largura, 3)$.

3.2 Espaços de cor

- **RGB:** modelo aditivo padrão de câmeras e monitores. Mistura cor e brilho nos três canais, dificultando isolar matizes específicos.
- **Escala de cinza:** intensidade luminosa única por pixel, obtida por média ponderada $(0,299R + 0,587G + 0,114B)$.
- **HSV (Matiz, Saturação, Valor):** separa a cor em três eixos perceptuais. Um pixel acinzentado tem saturação próxima de zero independentemente do brilho, o que permite rejeitar superfícies neutras com uma regra simples sobre o canal S .

3.3 Índices de vegetação

Folhas saudáveis refletem mais verde e absorvem mais vermelho (clorofila). Índices de vegetação exploram essa assinatura espectral.

VARI — Visible Atmospherically Resistant Index [1]

$$\text{VARI} = \frac{G - R}{G + R - B + \varepsilon} \quad (1)$$

Varia de -1 a $+1$; valores positivos indicam vegetação. O termo $\varepsilon = 10^{-6}$ evita divisão por zero. É resistente a variações de iluminação atmosférica.

ExG — Excess Green Index [2]

$$\text{ExG} = 2G - R - B \quad (2)$$

Simple e de baixo custo, com limiar natural em zero para segmentação.

ExGR — Excess Green minus Excess Red [3]

$$\text{ExR} = 1,4R - G \quad \text{ExGR} = \text{ExG} - \text{ExR} = 3G - 2,4R - B \quad (3)$$

Subtrai o excesso de vermelho, alto em solo e palha, separando melhor vegetação de fundo.

3.4 Filtros de suavização

- **Gaussiano:** convolução com *kernel* gaussiano; reduz ruído de alta frequência borrando indiscriminadamente.
- **Mediana:** substitui cada pixel pela mediana da vizinhança; eficaz contra ruído impulsivo, preserva bordas.
- **Bilateral:** média ponderada que respeita diferenças de cor; suaviza preservando bordas.

3.5 Detecção de bordas — Canny

O operador de Canny suaviza a imagem, calcula o gradiente, aplica supressão de não-máximos e usa histerese com dois limiares para conectar bordas fortes e fracas, evitando contornos quebrados.

3.6 Limiarização de Otsu

Otsu testa todos os limiares possíveis e escolhe o que **maximiza a variância entre as duas classes** de intensidade. Requer histograma bimodal para funcionar bem.

3.7 Morfologia matemática

Operações sobre máscaras binárias com um elemento estruturante. A *abertura* (erosão seguida de dilatação) remove ruído; o *fechamento* (dilatação seguida de erosão) preenche buracos.

3.8 Métricas de fidelidade — PSNR e SNR

$$\text{PSNR} = 10 \log_{10} \left(\frac{\text{MAX}^2}{\text{MSE}} \right) \quad \text{SNR} = 10 \log_{10} \left(\frac{P_{\text{signal}}}{P_{\text{ruído}}} \right) \quad (4)$$

Ambas medem, em decibéis, o quanto a imagem filtrada se afasta da original: valores maiores indicam maior fidelidade.

4 Metodologia

4.1 Ferramentas

O projeto foi desenvolvido em **Python 3.11** com as bibliotecas OpenCV 4.13, NumPy 2.4, Matplotlib 3.10, Pillow 12.2 e scikit-image 0.26, em ambiente Jupyter Lab.

4.2 Aquisição das imagens

Foram capturadas três imagens com câmera de smartphone (uma paisagem vegetada e duas cenas de teste) e selecionadas três imagens aéreas de drone para avaliar o comportamento do *pipeline* sob aquisição em ângulo *nadir* (visada vertical).

4.3 Pipeline de processamento

1. **Aquisição:** leitura com `cv2.imread()` e conversão $BGR \rightarrow RGB$;
2. **Pré-processamento:** inspeção de metadados, redimensionamento com `cv2.resize`, conversão para escala de cinza e normalização para $[0, 1]$;
3. **Análise inicial:** histograma dos canais R, G e B;
4. **Índices:** cálculo de VARI (com máscara de luminância) e ExG;
5. **Filtragem:** Gaussiano ($\sigma = 1,5$), Mediana (5×5) e Bilateral ($d = 9$), avaliados por PSNR e SNR;
6. **Detecção de bordas:** Canny com limiares 50 e 130;
7. **Segmentação:** Otsu (grayscale) *vs.* ExG, com refino morfológico;
8. **Segmentação aprimorada:** ExGR + trava HSV + preenchimento de buracos;
9. **Visualização:** *grid* comparativo de todos os estágios.

5 Resultados e Discussão

5.1 Aquisição e metadados

A imagem principal (`paisagem-verde.jpeg`) apresentou os seguintes metadados:

Tabela 1: Metadados da imagem principal.

Atributo	Valor
Resolução	2268×4032 pixels
Número de canais	3 (R, G, B)
Tipo (dtype)	<code>uint8</code> (0–255)
Tamanho em disco	1588,2 KB
Pixel [100, 200]	[20, 34, 19] (verde dominante)

O redimensionamento para 1024 px de largura (mantendo a proporção) resultou em 1024×1820 pixels, uma redução de **79,6%** no volume de dados — útil para prototipagem rápida.

5.2 Análise de histograma

A Figura 1 apresenta a distribuição de intensidades dos canais R, G, B e do índice ExG. Os três canais ocupam toda a faixa $[0, 1]$; o ExG concentra-se em valores positivos (média 0,084 na escala normalizada), confirmando dominância de verde na cena.




Figura 1: Histogramas dos canais de cor e do índice de vegetação ExG.

5.3 Índices de vegetação

O cálculo do VARI revelou um problema numérico relevante: em pixels de sombra, o denominador $G + R - B$ aproxima-se de zero, gerando *outliers* extremos (valores brutos de -11.764 a 235.294 antes do recorte). A solução adotada foi uma **máscara de luminância**, que zera o índice onde $(R + G + B)/3 < 0,1$: foram excluídos **521.887 pixels (5,71%)** de sombra, alterando a média do VARI de apenas 0,2483 para 0,2453 — confirmando que tais pixels eram ruído numérico, não sinal. A Figura 2 mostra os mapas de VARI e ExG.




Figura 2: Imagem original, mapa VARI (com máscara de luminância) e mapa ExG. Escala RdYlGn: vermelho indica ausência e verde indica presença de vegetação.

5.4 Filtragem comparativa

A Tabela 2 resume o desempenho dos três filtros, e a Figura 3 mostra o resultado visual.

Tabela 2: Comparação de filtros de suavização (imagem principal).

Filtro	PSNR (dB)	SNR (dB)	Tempo (ms)
Gaussiano $\sigma = 1,5$	25,39	18,66	50,3
Mediana 5×5	26,12	19,39	63,8
Bilateral $d = 9$	32,01	25,27	109,9

O filtro **bilateral** obteve o maior PSNR e SNR: por preservar bordas, afasta-se menos da imagem original, sendo o mais fiel numericamente apesar de visualmente suave. O Gaussiano, que borra indiscriminadamente, foi o menos fiel.



Figura 3: Comparação visual entre original e os filtros Gaussiano, Mediana e Bilateral.

5.5 Segmentação: Otsu *vs.* ExG

A Tabela 3 e a Figura 4 contrastam os dois métodos.

Tabela 3: Otsu (luminância) *vs.* ExG (crominância).

Método	Threshold	Cobertura	Regiões
Otsu (grayscale)	0,5294	13,08%	259
ExG fixo (> 0)	0,0000	82,24%	150

Otsu segmenta por **brilho**: o limiar 0,53 separa pixels claros de escuros, detectando apenas 13% e fragmentando a cena em 259 regiões. O ExG segmenta por **assinatura espectral**, detectando 82% em apenas 150 regiões coerentes. Conclui-se que, para imagens RGB de campo, a limiarização por índice espectral é metodologicamente superior à de Otsu por luminância, que descarta a informação de crominância que define a vegetação.




Figura 4: Máscaras de segmentação por Otsu (grayscale) e por ExG, após refino morfológico (MORPH_OPEN + MORPH_CLOSE, kernel elíptico 7×7).

5.6 Segmentação aprimorada

A segmentação ingênua ($\text{ExG} > 0$) produz **falsos positivos** em céu, solo claro e superfícies acinzentadas. A versão aprimorada combina o índice ExGR com uma **trava de cor em HSV** ($H \in [30, 95]$, $S \geq 40$, $V \geq 30$), preenchimento de buracos e filtragem por área mínima. Como ambos os testes são **absolutos** (não relativos como o Otsu), evitam tanto falsos positivos quanto os falsos negativos que o Otsu causaria em cenas uniformemente verdes. A Tabela 4 quantifica a correção.

Tabela 4: Evolução da segmentação em três imagens de drone (% de vegetação).

Imagem	ExG>0 (ingênuo)	ExGR+HSV (final)	Leitura
campo-fazenda	86,7%	63,0%	céu e estrada excluídos
vegetação-densa	99,6%	96,4%	recupera vegetação real
lavoura-solo	97,4%	39,1%	solo marrom excluído




Figura 5: Antigo *vs.* aprimorado: o céu e a estrada deixam de ser classificados como vegetação. Da esquerda para a direita: original, máscara ingênua, máscara final e contornos filtrados sobre a imagem.

5.7 Análise multi-imagem

O *pipeline* foi aplicado às seis imagens do projeto (Tabela 5, Figura 6).

Tabela 5: Análise multi-imagem com índice ExG (*baseline*).


Imagem	Origem	Veg. (%)	VARI médio
WhatsApp 17:57	celular	8,86	−0,1365
WhatsApp 18:00	celular	97,08	−0,0016
paisagem-verde	celular	85,20	+0,2453
drone-campo-fazenda	drone	87,85	+0,1397
drone-vegetação-densa	drone	99,35	+0,1744
drone-lavoura-solo	drone	97,68	−0,0695

Destaca-se a divergência na imagem **drone-lavoura-solo**: o ExG indica 97,68% de vegetação, mas o VARI médio é negativo (−0,0695). Trata-se de uma superestimação do ExG sobre solo avermelhado — precisamente o falso positivo que a segmentação aprimorada corrige (de 97,68% para 39,1%).

WhatsApp Image 2026-05-10 at 17.57.38
Original



VARI (médio: -0.137)




ExG overlay (8.9% vegetação)



WhatsApp Image 2026-05-10 at 18.00.46
Original



VARI (médio: -0.002)




ExG overlay (97.1% vegetação)




drone-campo-fazenda
Original




VARI (médio: 0.140)




ExG overlay (87.9% vegetação)




drone-lavoura-solo
Original




VARI (médio: -0.069)



ExG overlay (97.7% vegetação)




drone-vegetacao-densa
Original




VARI (médio: 0.174)




ExG overlay (99.3% vegetação)



paisagem-verde
Original



VARI (médio: 0.245)



ExG overlay (85.2% vegetação)



5.8 Pipeline completo

A Figura 7 consolida todos os estágios em um único painel.




Figura 7: Grid comparativo 2×5 com todos os estágios do pipeline, gerado a 300 dpi.

6 Análise Crítica

Os experimentos sustentam três conclusões técnicas:

1. **Crominância supera luminância.** Para vegetação em imagens RGB, índices de cor (ExG, VARI, ExGR) são superiores à limiarização de Otsu por brilho, que ignora a informação espectral que define a planta.
2. **Testes absolutos superam testes relativos.** O limiar fixo erra por excesso (falsos positivos); o Otsu erra por falta em cenas uniformes (falsos negativos). A combinação *absoluta* ExGR + HSV equilibra os dois extremos.
3. **A imagem é parte do algoritmo.** Fotos de celular em ângulo oblíquo apresentam sombras e misturas de superfície que degradam os índices; imagens de drone em visada *nadir* produzem resultados muito mais limpos, pois cada pixel representa uma única superfície.

Limitações. Imagens de satélite multiespectrais não são adequadas a estes índices, projetados para câmeras RGB de superfície. O processamento interno de smartphones (HDR, saturação) também pode distorcer a crominância.

7 Conclusão

O *pipeline* desenvolvido cumpre todas as etapas propostas — aquisição, pré-processamento, análise de histograma, filtragem, detecção de bordas, segmentação e visualização — e vai além ao implementar índices espectrais especializados e uma segmentação de alta precisão que elimina falsos positivos. Demonstrou-se que técnicas de processamento de imagem extraem informação quantitativa de vegetação invisível a olho nu, e que a qualidade do resultado depende tanto do algoritmo quanto da adequação da imagem de entrada. Como trabalho futuro, sugere-se a validação com imagens de drone de alta resolução em diferentes culturas e a integração com câmeras multiespectrais para o cálculo do NDVI.

Referências

- [1] GITELSON, A. A. *et al.* **Novel algorithms for remote estimation of vegetation fraction.** Remote Sensing of Environment, v. 80, n. 1, p. 76–87, 2002.
- [2] WOEBBECKE, D. M. *et al.* **Color indices for weed identification under various soil, residue, and lighting conditions.** Transactions of the ASAE, v. 38, n. 1, p. 259–269, 1995.
- [3] MEYER, G. E.; NETO, J. C. **Verification of color vegetation indices for automated crop imaging applications.** Computers and Electronics in Agriculture, v. 63, n. 2, p. 282–293, 2008.
- [4] GONZALEZ, R. C.; WOODS, R. E. **Processamento Digital de Imagens.** 3. ed. São Paulo: Pearson, 2010.
- [5] BRADSKI, G.; KAEHLER, A. **Learning OpenCV 4: Computer Vision with Python 3.** O'Reilly Media, 2019.
- [6] OPENCV. **OpenCV Documentation.** Disponível em: <https://docs.opencv.org/4.x/>.
- [7] SCIKIT-IMAGE. **Documentation.** Disponível em: <https://scikit-image.org/docs/stable/>.

Repositório do projeto: <https://github.com/GilbertoPaiva/cv-vegetation-indices>